FBDP作业七

Kmeans的设计思路

Kmeans的主要逻辑是聚类，关键在于如何将"相似"点分配在一个类别中；而"相似度"的判断则来自我们对distance计算的逻辑与选取的距离公式。

1. 随机选取三个数据点，并根据最短distance原则，将剩余点分到着三个类别中
2. 每个类别的点，求平均横坐标与纵坐标，形成新的中心点，再次分类
3. 迭代过程2
4. 最后输出分类结果

所遇到的问题

1. Intellij的maven项目没有package：

   首先，本次Kmeans代码较长较复杂，网络上的操作方法一般需要多个class协助完成。而在前两次作业的设计中发现Intellij Maven打包的项目中没有设定package。

   解决方法：首先对/src/java邮件，选择mark directory as resource root，自动导入package。
2. 多个class的情况下，如何写pom.xml?

   首先要设置好package的名称，在每个class中都要标注引入package。在pom中要注明最主要的main class在哪。
3. 不理解第一次reduce输出后，value为所有属于该类的点应该如何处理？

   解决：实际上，第一次reduce输出后，只有key，也就是cluster的平均坐标将被使用，而后续继续计算的点坐标又将来自于input文件。
4. 发现问题：第一次迭代输出为空，但是最初init部分可以得到目标结果，而两次map-reduce进程均使用相同的reducer。问题可能出现在迭代文件引用安排上。

```
yuanshan@yuanshan-virtual-machine:~/下载/kmeans$ hdfs dfs -ls /kmeans/output/Dat
a0
Found 2 items
-rw-r--r--   1 yuanshan supergroup          0 2020-11-08 10:24 /kmeans/output/Da
ta0/_SUCCESS
-rw-r--r--   1 yuanshan supergroup        672 2020-11-08 10:24 /kmeans/output/Da
ta0/part-r-00000
yuanshan@yuanshan-virtual-machine:~/下载/kmeans$ hdfs dfs -get /kmeans/output ./
output
2020-11-08 10:34:07,124 INFO sasl.SaslDataTransferClient: SASL encryption trust
check: localHostTrusted = false, remoteHostTrusted = false
yuanshan@yuanshan-virtual-machine:~/下载/kmeans$ cd output
yuanshan@yuanshan-virtual-machine:~/下载/kmeans/output$ ls
Data0  Data1
yuanshan@yuanshan-virtual-machine:~/下载/kmeans/output$ cd Data0
yuanshan@yuanshan-virtual-machine:~/下载/kmeans/output/Data0$ ls
part-r-00000  _SUCCESS
yuanshan@yuanshan-virtual-machine:~/下载/kmeans/output/Data0$ cd ..
yuanshan@yuanshan-virtual-machine:~/下载/kmeans/output$ vim Data0/part-r-00000
yuanshan@yuanshan-virtual-machine:~/下载/kmeans/output$ vim Data1/part-r-00000
yuanshan@yuanshan-virtual-machine:~/下载/kmeans/output$ cd Data1
yuanshan@yuanshan-virtual-machine:~/下载/kmeans/output/Data1$ ls
yuanshan@yuanshan-virtual-machine:~/下载/kmeans/output/Data1$
```

Debug思路：由于涉及文件读取 - mapper - reducer -文件存储 这样的过程，首先验证原参考代码的正确性。若仍然无法通过，说明是文件读取方式不同造成的差异，应当修正为之前用过的文件读取方法。若通过，则说明多个main函数加在一个class里面的运用有问题，不应该以目前代码的组织形式构建。

发现：按照作者的class组织架构进行运行，仍然有找不到文件的错误，说明文件加载方式出现了问题。

决定使用另外的文件组织形式，参考之前的"共同好友"以及官网提供的wordcount方式进行更改。

详细分析发现：原文作者使用的是

```
DistributedCache.getLocalCacheFiles(conf)
```

获得之前reduce产出的文件，实际操作时应该是在local上查找文件，而非在Hdfs上查找，从此处报错信息可以分析原因：

```
2020-11-08 14:33:46,800 INFO mapred.MapTask: Map output collector class = org.ap
ache.hadoop.mapred.MapTask$MapOutputBuffer
2020-11-08 14:33:46,817 INFO mapred.MapTask: Starting flush of map output
2020-11-08 14:33:46,830 INFO mapred.LocalJobRunner: map task executor complete.
2020-11-08 14:33:46,840 WARN mapred.LocalJobRunner: job_local418126945_0002
java.lang.Exception: java.io.FileNotFoundException: file:/usr/local/hadoop/tmp/m
apred/local/job_local418126945_0002_8f3215db-4626-4b6a-ba43-2d904c76da64/part-r-
00000 (没有那个文件或目录)
        at org.apache.hadoop.mapred.LocalJobRunner$Job.runTasks(LocalJobRunner.j
ava:492)
        at org.apache.hadoop.mapred.LocalJobRunner$Job.run(LocalJobRunner.java:5
52)
Caused by: java.io.FileNotFoundException: file:/usr/local/hadoop/tmp/mapred/loca
l/job_local418126945_0002_8f3215db-4626-4b6a-ba43-2d904c76da64/part-r-00000 (没
有那个文件或目录)
        at java.io.FileInputStream.open0(Native Method)
        at java.io.FileInputStream.open(FileInputStream.java:195)
        at java.io.FileInputStream.<init>(FileInputStream.java:138)
        at java.io.FileInputStream.<init>(FileInputStream.java:93)
        at java.io.FileReader.<init>(FileReader.java:58)
        at com.cys.kms.kmeansIter$PRIterMapper.setup(kmeansIter.java:52)
        at org.apache.hadoop.mapreduce.Mapper.run(Mapper.java:143)
        at org.apache.hadoop.mapred.MapTask.runNewMapper(MapTask.java:799)
```

导致迭代开始，第一次迭代数据产出文件无法找到。

于是我换成

```
Job.*getInstance*(conf).getCacheFiles()
```

发现仍然找不到第一次迭代数据产出文件，检查报错发现，是阅读文件时string转double出现了错误，导致Mapper环节setup失败。修改后导出成功。

5. 将迭代次数调整为20，查看输出结果。

```
                Merged Map outputs=1
                GC time elapsed (ms)=0
                Total committed heap usage (bytes)=1015021568
        Shuffle Errors
                BAD_ID=0
                CONNECTION=0
                IO_ERROR=0
                WRONG_LENGTH=0
                WRONG_MAP=0
                WRONG_REDUCE=0
        File Input Format Counters
                Bytes Read=584
        File Output Format Counters
                Bytes Written=784
yuanshan@yuanshan-virtual-machine:~/下载/kmeans$ hdfs dfs -get /kmeans/output ./
output
2020-11-08 16:01:43,016 INFO sasl.SaslDataTransferClient: SASL encryption trust
check: localHostTrusted = false, remoteHostTrusted = false
yuanshan@yuanshan-virtual-machine:~/下载/kmeans$ cd output
yuanshan@yuanshan-virtual-machine:~/下载/kmeans/output$ ls
Data0   Data11  Data14  Data17  Data2   Data4  Data7  FinalRank
Data1   Data12  Data15  Data18  Data20  Data5  Data8
Data10  Data13  Data16  Data19  Data3   Data6  Data9
yuanshan@yuanshan-virtual-machine:~/下载/kmeans/output$
```

```
0       80,99
0       76,94
0       93,46
0       60,68
0       70,23
0       79,43
0       88,98
0       83,33
0       86,43
0       73,93
0       58,74
0       96,47
0       61,36
0       87,75
0       100,60
0       96,66
0       99,54
0       89,27
0       62,69
0       81,86
0       61,82
0       72,60
0       81,28
"FinalRank/part-r-00000" 100L, 784C                           1,1           顶端
```

下面打算使用python将结果以可视化形式展示输出。

```
In [45]: df.plot(kind = "scatter", x = "x_axis", y = "y_axis", c = "center", alpha = 0.4)
Out[45]: <matplotlib.axes._subplots.AxesSubplot at 0x7fae5dd4d350>
```

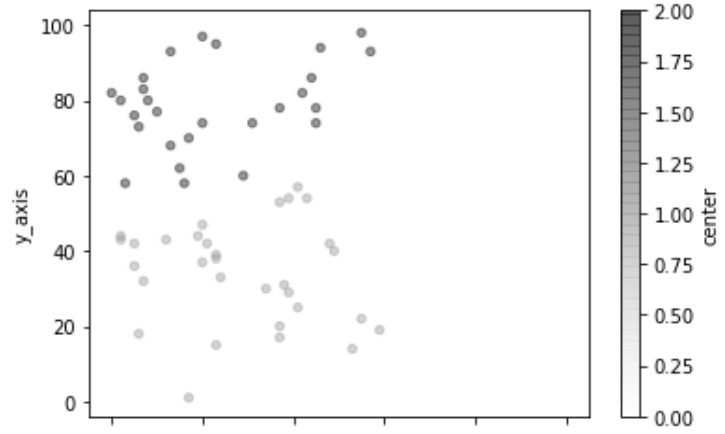

可以完善的地方

1. 分几个类别、开始几个点，应该可以由用户交互输入
2. 应随机取三个点，而非人工在代码中选定初始值
3. Java的原则是oop，那么在写class时，应该分类更有层次，使得对象结构清晰，代码可读性更高